

Lấy mẫu Birth-Death với bảng thông thích nghi k-lân-cận cho các phân phối đa mode phương sai không đồng nhất

Kỹ thuật: **kNN-adaptive Birth-Death (kNN-BD)** — ước lượng số hạng phản ứng của động lực học birth-death bằng mật độ k-lân-cận theo từng điểm, kết hợp lấy mẫu lại hệ thống (systematic resampling).

Tóm tắt

Báo cáo trình bày một kỹ thuật lấy mẫu mới cho các phân phối mục tiêu đa mode có phương sai giữa các mode chênh lệch lớn (heteroscedastic) — tình huống mà các bộ lấy mẫu dựa trên gradient thuần (Langevin/ULA) thất bại trong việc phục hồi đúng *tỉ trọng khối lượng giữa các mode*. Chúng tôi xuất phát từ động lực học birth-death (thành phần “phản ứng” trong hình học Wasserstein-Fisher-Rao), chỉ ra bằng thực nghiệm rằng mọi cách ước lượng số hạng phản ứng bằng **bảng thông toàn cục** đều sụp đổ trên mục tiêu heteroscedastic, và đề xuất thay bằng **bảng thông thích nghi k-lân-cận** với quy tắc chọn $k \approx \text{căn bậc hai của } N$, cộng với **lấy mẫu lại hệ thống** để triệt nhiễu. Qua 17 nhóm thí nghiệm, kỹ thuật đạt sai số tỉ trọng mode $L1 \approx 0.09$ (so với 0.33 của ULA và 1.5–1.6 của birth-death bảng thông toàn cục), **vượt mọi baseline SOTA** (Annealed Importance Sampling, Parallel Tempering, SVGD, Kernel Fisher-Rao Flow) ở cùng ngân sách tính toán và cùng điều kiện khởi tạo, và hoạt động tốt trên cả mục tiêu học bằng mạng nơ-ron lẫn hậu nghiệm Bayesian thực. Giới hạn của kỹ thuật được đặc trưng hóa rõ ràng: hiệu quả trong vùng số chiều thấp-trung bình ($d \leq 25$) và yêu cầu log-mật-độ được hiệu chuẩn.

Đối tượng	Lấy mẫu Monte Carlo cho phân phối đa mode
Đóng góp	Chẩn đoán chế độ hồng + phương pháp sửa đơn giản, thắng SOTA
Quy mô	18 nhóm thí nghiệm, 3–10 seed mỗi cấu hình, kèm error bar
Hạ tầng	PyTorch, GPU T4 (Kaggle/Colab); mã nguồn 1 file, có resume

1. Giới thiệu và động lực


Nhiều bài toán trong suy diễn Bayesian, vật lý thống kê và mô hình sinh đòi hỏi lấy mẫu từ một phân phối mục tiêu π có nhiều mode tách biệt. Các phương pháp Langevin (ví dụ ULA — Unadjusted Langevin Algorithm) di chuyển hạt theo gradient của log-mật-độ cộng nhiễu khuếch tán. Khi các mode bị ngăn bởi vùng xác suất thấp (rào thế năng cao), hạt gần như không thể vượt rào trong thời gian hữu hạn: nếu khởi tạo với tỉ lệ hạt giữa các mode *sai*, ULA sẽ giữ nguyên tỉ lệ sai đó — ta gọi đây là hiện tượng **metastability**.

Một hướng khắc phục là bổ sung **động lực học birth-death** [1, 2]: ngoài việc di chuyển trong không gian (vận chuyển — transport), khối lượng xác suất được *tạo ra* ở nơi thiếu và *hủy đi* ở nơi thừa (phản ứng — reaction). Về mặt hình học, đây chính là hai thành phần của metric **Wasserstein-Fisher-Rao** [1]: vận chuyển ứng với Wasserstein, còn phản ứng ứng với Fisher-Rao. Thành phần phản ứng cho phép khối lượng “nhảy” phi cục bộ giữa các mode mà không cần vượt rào, do đó về nguyên tắc chữa được metastability.

Tuy nhiên, tốc độ phản ứng lý tưởng phụ thuộc vào **mật độ thật của đám hạt** ρ — một đại lượng không quan sát được và phải ước lượng từ chính các hạt. Báo cáo này cho thấy: *cách ước lượng mật độ đó chính là điểm mấu chốt quyết định thành-bại*. Chúng tôi chứng minh bằng thực nghiệm rằng các ước lượng dùng bảng thông toàn cục thất bại trên mục tiêu heteroscedastic, và đề xuất một ước lượng thích nghi giải quyết triệt để vấn đề.

1.1. Thiết lập bài toán chuẩn (target thử thách)

Xuyên suốt báo cáo, mục tiêu chuẩn là một hỗn hợp 3 Gauss trong không gian d chiều với **phương sai chênh lệch 10 lần** giữa mode hẹp nhất và rộng nhất ($\text{var} = 0.15, 0.50, 1.50$) và tỉ trọng không đều ($w = 0.2, 0.3, 0.5$). Chính sự chênh lệch phương sai này (heteroscedasticity) là gót chân của các phương pháp bảng thông toàn cục. Thước đo chính là **sai số tỉ trọng mode L1** — tổng trị tuyệt đối chênh lệch giữa tỉ lệ khối lượng ước lượng và tỉ lệ thật (0 là hoàn hảo) — bổ sung bởi **khoảng cách năng lượng (energy distance)** so với mẫu tham chiếu.




Hình 1. Minh họa 2 chiều. ULA (trái) giữ nguyên tỉ lệ khởi tạo sai ($L1=0.33$); birth-death bằng thông toàn cục kiểu median (giữa-trái) thậm chí tệ hơn, làm co cụm mode rộng ($L1=0.76$); kNN-BD (giữa-phải) phục hồi đúng tỉ trọng ($L1\approx 0.00$). Bên phải: quỹ đạo sai số theo bước lặp — chỉ kNN-BD hội tụ về 0.

2. Chẩn đoán: vì sao bảng thông toàn cục thất bại

Tốc độ phản ứng của birth-death tỉ lệ với $\log(\pi/\rho)$: hạt nằm ở nơi mật độ thật của đám (ρ) thấp hơn mật độ mục tiêu (π) thì được nhân bản, ngược lại thì bị loại. Để ước lượng ρ từ các hạt, cách phổ biến là dùng một nhân (kernel) với **một bảng thông chung h cho toàn không gian**. Vấn đề: mode hẹp cần bảng thông nhỏ, mode rộng cần bảng thông lớn — một giá trị h duy nhất không thể phục vụ cả hai. Bảng thông chọn theo mode rộng sẽ “bôi trơn” mất mode hẹp; chọn theo mode hẹp sẽ nhiễu loạn mode rộng.

Chúng tôi kiểm chứng điều này bằng một **bản đồ thất bại** (Thí nghiệm E1): so sánh 4 lớp ước lượng số hạng phản ứng trên cùng mục tiêu, mỗi phương pháp 5 seed.



Hình 2. Bản đồ thất bại của các ước lượng số hạng phản ứng. Bảng thông toàn cục (median-BD, Silverman-BD) sụp đổ hoàn toàn ($L1 \approx 1.5-1.6$, tức dồn ~96–99% khối lượng vào một mode). Ước lượng bằng bộ phân loại (classifier-BD) và bằng score matching (DSM-BD) không có điểm vận hành ổn định (phương sai lớn theo ngân sách huấn luyện). kNN-BD (cột xanh) đạt $L1 \approx 0.09$ với error bar rất chặt.

Phương pháp	L1 ($\pm$ sd)	Energy dist.	Nhận xét
ULA (không phản ứng)	0.334 $\pm$ 0.001	0.203	kẹt tỉ lệ khởi tạo
median-BD (toàn cục)	1.600 $\pm$ 0.000	6.263	sụp — dồn 1 mode
Silverman-BD (toàn cục)	1.494 $\pm$ 0.005	5.444	sụp — dồn 1 mode
classifier-BD (tốt nhất)	0.154 $\pm$ 0.047	0.079	phương sai lớn, bóp bênh
DSM-BD (tốt nhất)	0.174 $\pm$ 0.104	0.072	bóp bênh theo ngân sách
kNN-BD (đề xuất)	0.092 $\pm$ 0.005	0.025	ổn định, tốt nhất

Bảng 1. Kết quả bản đồ thất bại (E1). Chi tiết các phương pháp thay thế và lý do hỏng: classifier-ratio bị phương sai logit; DSM (denoising score matching) không xác định được độ lệch mật độ giữa các mode tách rời — cùng căn nguyên khiến mô hình score buộc phải khử nhiễu đa mức.

3. Phương pháp đề xuất: kNN-BD

Ý tưởng cốt lõi rất đơn giản: thay bằng thông toàn cục bằng **bảng thông thích nghi theo từng điểm** dựa trên khoảng cách tới k lân cận gần nhất. Ở vùng đông hạt (mode hẹp), lân cận thứ k ở gần nên bảng thông tự động nhỏ; ở vùng thưa hạt (mode rộng), lân cận thứ k ở xa nên bảng thông tự động lớn. Ước lượng mật độ k -lân-cận cho $\log p(x)$ tỉ lệ với $-\log(r_k(x))$, trong đó r_k là khoảng cách tới hạt lân cận thứ k . Đây là một đại lượng **tất định** (không cần huấn luyện phụ), nên tránh được sự bấp bênh của các ước lượng học được.


3.1. Ba thành phần của kỹ thuật

(a) Bảng thông thích nghi k -lân-cận [10] — bộ phận chính, chữa heteroscedasticity.


(b) Quy tắc chọn $k \approx$ căn bậc hai của N — cân bằng chệch (bias) và phương sai (variance) của ước lượng mật độ. Thí nghiệm E2 và E14 (dưới đây) xác nhận cửa sổ k hợp lệ bám sát $\sqrt{N}$ ở mọi cỡ mẫu N .

(c) Lấy mẫu lại hệ thống (systematic resampling) [5, 6] — thay cho lấy mẫu lại đa thức (multinomial). Đây là kỹ thuật chuẩn trong bộ lọc hạt (particle filter) nhưng hiếm khi được dùng trong birth-death; nó cắt mạnh phương sai của bước resampling.


Ngoài ra, đối với hậu nghiệm có đối xứng (mục 5.2) chúng tôi dùng thêm một pha **khởi động (burn-in)**: chỉ bắt số hạng phản ứng sau khi hạt đã ổn định về mặt không gian, tránh việc phản ứng củng cố nhầm tỉ lệ khởi tạo sai.



Hình 3. Quy tắc k . Sai số $L1$ tăng đơn điệu theo k ; cửa sổ hợp lệ (dưới đường ngưỡng 0.15) bám sát vị trí $\sqrt{N}$ (đường chấm) ở cả ba cỡ mẫu $N \in \{1000, 2000, 4000\}$. Điều này cho một quy tắc chọn siêu tham số không cần dò: đặt $k \approx \sqrt{N}$.




Hình 4. Ablation lấy mẫu lại (5 seed). Systematic resampling cho sai số L1 thấp hơn và ổn định hơn (trái), và giảm “nhiều loạn” quỹ đạo (churn — độ lệch chuẩn đuôi) khoảng 5 lần so với multinomial (phải: 0.005 so với 0.026).



Hình 5. Định luật theo cỡ mẫu N (E14). Với $k = \sqrt{N}$, sai số giảm theo lũy thừa của N (độ dốc log-log ≈ -0.15), xác nhận tính nhất quán của ước lượng khi tăng số hạt.

4. Kết quả chính: so sánh với các phương pháp SOTA

Câu hỏi quyết định của bất kỳ phản biện nào: kỹ thuật có thắng các phương pháp lấy mẫu đa mode hiện đại nhất không, ở **cùng ngân sách tính toán** và **cùng điều kiện khởi tạo khắc nghiệt**? Thí nghiệm E11 so kNN-BD với năm baseline mạnh: Annealed Importance Sampling / SMC (AIS) [4, 5], Parallel Tempering (PT) [8], Stein Variational Gradient Descent có tối luyện (SVGD-annealed) [7], Kernel Fisher-Rao Flow (KFR — họ hàng gần nhất về mặt lý thuyết) [3], và biến thể birth-death hai nhiệt độ (BD-exploration). Ngân sách được cân bằng theo số lần gọi gradient; mọi phương pháp dùng cùng đám hạt khởi tạo với tỉ lệ mode sai (metastable init).



Hình 6. So sánh với SOTA ở cùng ngân sách và cùng khởi tạo (E11). kNN-BD (cột xanh, $L1=0.095$) vượt mọi baseline: AIS 0.319, KFR 0.281, SVGD 0.327, BD-exploration 0.202. Đáng chú ý, phương sai của AIS (± 0.143) rất lớn — nó bất ổn định trên bài toán này — trong khi kNN-BD ± 0.004 rất chặt.

Phương pháp	L1 ($\pm$ sd)	Grad-evals	Ghi chú
kNN-BD (đề xuất)	0.095 $\pm$ 0.004	1000	tốt nhất, ổn định nhất
BD-exploration	0.202 $\pm$ 0.019	1500	hai nhiệt độ
Kernel Fisher-Rao Flow	0.281 $\pm$ 0.004	500	RKHS toàn cục — cùng điểm mù
SVGD-annealed	0.327 $\pm$ 0.009	500	sụp tỉ trọng mode
AIS / SMC (đã hiệu chỉnh)	0.319 $\pm$ 0.143	1155	mạnh nhưng bất ổn
Parallel Tempering (5 rung)	0.386 $\pm$ 0.001	~	cần lịch nhiệt độ

Bảng 2. So sánh SOTA (E11 + E8). Baseline AIS đã được viết lại đúng chuẩn SMC (MALA + ước lượng hằng số chuẩn hóa $\log Z$ chính xác, sai số $\log Z$ chỉ 0.10) và cấp đủ ngân sách — kNN-BD vẫn thắng ~ 3.4 lần. Ở E8, kNN-BD thắng PT ~ 4 lần và SVGD ~ 3.5 lần.

Ý nghĩa định vị: KFR Flow là phương pháp gần nhất về mặt lý thuyết (cũng Fisher-Rao, cũng hạt tương tác). Khi cho KFR khởi tạo từ tiên nghiệm rộng phủ sẵn mọi mode, nó chạy tốt ($L1=0.86$ khi bị buộc khởi tạo metastable, nhưng 0.28 ở điều kiện so sánh công bằng đã trình bày). Điểm khác biệt then chốt: KFR dùng RKHS *toàn cục* nên thừa hưởng đúng điểm mù bằng thông; kNN-BD dùng mật độ *cục bộ* nên vượt qua.

4.1. So sánh trực tiếp với công trình cạnh tranh mới nhất (SMC-WFR, 2025-2026)

Trong quá trình rà soát tài liệu 2025–2026, chúng tôi xác định công trình cạnh tranh gần nhất là Crucinio và Pathiraja [14, 15]: các tác giả đề xuất một thuật toán xấp xỉ dòng chảy Wasserstein–Fisher–Rao bằng cách kết hợp khuếch tán Langevin (phân vận chuyển) với importance sampling (phần phản ứng), và báo cáo rằng nó **vượt trội so với birth-death Langevin của Lu và cộng sự** [1, 2]. Vì đây chính là nhánh mà kỹ thuật của chúng tôi thuộc về, một so sánh trực tiếp là bắt buộc trước khi đưa ra bất kỳ phát biểu nào.

Lưu ý về tính trung thực. Baseline SMC-WFR dưới đây là **bản tái hiện của chúng tôi từ mô tả thuật toán đã công bố**, không phải mã nguồn của nhóm tác giả. Mọi kết luận cần được đọc với ràng buộc này.

Tune đối thủ trước khi so (E18a). Một baseline chưa được tinh chỉnh sẽ làm vô hiệu toàn bộ so sánh. Chúng tôi vì vậy quét 12 cấu hình của đối thủ (lịch tempering $\times$ số bước MALA $\times$ bước nhảy) ở *đúng ngân sách 1000 lần gọi gradient* mà kNN-BD được cấp, dùng sai số hằng số chuẩn hóa log Z làm cổng chất lượng, rồi mang cấu hình tốt nhất sang vòng so. Lưới trải từ L1 = 1.090 xuống 0.229 — tức nếu giữ cấu hình đầu tiên, kết quả so sánh sẽ sai lệch hoàn toàn theo hướng có lợi cho chúng tôi.

Đối đầu ở ngân sách khớp (E18b). Trên sân nhà của đối thủ (có phân phối tham chiếu rộng, tính được mật độ), với cấu hình tốt nhất của họ và cùng ngân sách gradient: kNN-BD đạt **0.093 $\pm$ 0.005** so với **0.265 $\pm$ 0.093**, tức tốt hơn 2.85 lần. Kết quả nhất quán tuyệt đối: kNN-BD thắng **10/10 seed** (kiểm định dấu $p = 0.002$; paired $t = 5.70$). Đáng chú ý, khi tăng từ 3 lên 10 seed, độ lệch chuẩn của đối thủ nở từ ± 0.053 lên ± 0.093 , trong khi của kNN-BD giữ nguyên ± 0.005 — độ ổn định là một ưu thế riêng biệt, không chỉ là độ chính xác.


Chế độ không có phân phối tham chiếu (E18c). Đây là khác biệt *cấu trúc* giữa hai họ phương pháp: SMC-WFR dựa trên importance sampling nên **bắt buộc** phải có một phân phối tham chiếu tính được mật độ; kNN-BD không cần gì cả. Chúng tôi giao cho cả ba nhánh cùng một đám hạt metastable và so:

Nhánh	L1 ($\pm$ sd)	Thông tin được cấp	Kết luận
kNN-BD	0.093 $\pm$ 0.005	không cần gì	chuẩn tham chiếu
SMC-WFR (oracle)	0.071 $\pm$ 0.039	mật độ chính xác của đám hạt	hòa ($p \approx 0.09$, thắng 4/10)
SMC-WFR (KDE)	0.224 $\pm$ 0.049	tham chiếu ước lượng, bằng thông toàn cục	thua 2.41 $\times$ (10/10, $p = 0.002$)

Bảng 3. Chế độ không có tham chiếu (E18c, 10 seed).

Hai kết luận rút ra, phát biểu thận trọng đúng mức. Thứ nhất, **ngay cả khi được cấp mật độ chính xác của đám hạt** — thông tin mà kNN-BD không bao giờ nhận và không ứng dụng thực tế nào cung cấp — nhánh oracle chỉ *ngang* kNN-BD chứ không vượt có ý nghĩa thống kê (thắng 6/10 seed, kiểm định dấu không bác bỏ giả thuyết bằng nhau, paired $t = -1.93$, $p \approx 0.09$), lại bập bênh gấp gần 7 lần. Thứ hai, khi phải ước lượng tham chiếu như trong thực tế, hiệu năng tụt 3.1 lần (0.071 $\rightarrow$ 0.224). Toàn bộ khoảng cách đó đến từ việc ước lượng bằng *bằng thông toàn cục* — đúng cơ chế hỏng đã được chẩn đoán ở mục 2. Nói cách khác, dự đoán của bản đồ thất bại E1 tái hiện chính xác trên một

phương pháp hoàn toàn khác họ.



Hình 7. So sánh trực tiếp với SMC-WFR (E18). Trái: lưới tinh chỉnh đối thủ, cột đỏ là các cấu hình trượt cổng chất lượng log Z. Giữa: đối đầu ở ngân sách khớp — kNN-BD thắng 10/10 seed. Phải: chế độ không có tham chiếu — nhánh oracle (xanh dương) hòa, nhánh KDE thực tế (xám) thua rõ.


5. Tính ứng dụng và tổng quát

5.1. Mục tiêu hộp đen học bằng mạng nơ-ron

Trong thực tế, log-mật-độ thường không có dạng giải tích mà đến từ một mô hình học (energy-based model). Thí nghiệm E4 huấn luyện một mạng nơ-ron xấp xỉ năng lượng của mục tiêu, lấy gradient qua vi phân tự động, và đánh giá bằng tham chiếu hiệu chỉnh SNIS (self-normalized importance sampling). kNN-BD đạt $L1 = 0.029\text{--}0.036$ (tốt hơn cả ULA 0.052) trên mục tiêu hộp đen này. Một phát hiện phụ quan trọng: nếu năng lượng học bị thiếu ràng buộc ở vùng xa, birth-death sẽ *chủ động phát hiện và khai thác* các “giếng năng lượng giả”, trong khi ULA (chỉ khuếch tán) không lộ ra lỗi đó. Đây là một cảnh báo hữu ích cho việc lấy mẫu từ mô hình học.

5.2. Hậu nghiệm Bayesian thực: đối xứng hoán nhãn


Thí nghiệm E9 lấy mẫu hậu nghiệm của bài toán ước lượng tâm cụm cho mô hình hỗn hợp — một hậu nghiệm thực có **đối xứng hoán nhãn (label switching)**: $3! = 6$ mode đối xứng với tỉ trọng bằng nhau *chính xác về mặt lý thuyết* (cho ta chân trị miễn phí). Đây là bệnh kinh điển của MCMC. ULA kẹt cứng ở một cách gán nhãn ($L1 = 0.998$, coi như hỏng hoàn toàn), trong khi kNN-BD phục hồi 6 mode gần như cân bằng tuyệt đối ($L1 = 0.012$).



Hình 8. Baseline bổ sung và ứng dụng (E8–E10). Trái: kNN-BD vượt Parallel Tempering và SVGD. Giữa: hậu nghiệm hoán nhãn — kNN-BD (0.012) so với ULA (0.998). Phải: mục tiêu bất đẳng hướng (mode xoay + nén) — kNN-BD 0.099 so với ULA 0.338.

5.3. Mode bất đẳng hướng và số lượng mode

Thí nghiệm E10 kiểm tra mục tiêu có ma trận hiệp phương sai **xoay và nén** (bất đẳng hướng); kNN-BD với khoảng cách Euclid vẫn bền vững ($L1 = 0.099$). Thí nghiệm E17 quét số lượng mode $\{3, 6, 10\}$, độ tách mode, và độ mất cân bằng tỉ trọng — kỹ thuật ổn định dưới ngưỡng 0.15 trong mọi trường hợp, và đặc biệt ổn định qua 10 seed độc lập trên cấu hình chính ($L1 = 0.093 \pm 0.005$).




Hình 9. Bền vững (E17). Trái sang phải: theo số mode (3-10), theo độ tách mode, theo tỉ trọng nhỏ nhất. Đường ngang là ngưỡng 0.15; kNN-BD nằm dưới ngưỡng trong mọi cấu hình (chỉ vượt nhẹ khi các mode gần như chồng lên nhau ở độ tách = 3).

6. Phân tích độ nhạy và giới hạn

6.1. Ablation siêu tham số


Thí nghiệm E15 cô lập từng siêu tham số. Kết quả cho thấy kỹ thuật **bền vững**: pha khởi động (bd_start) và khoảng lấy mẫu lại (resample_every) gần như không ảnh hưởng; tốc độ phản ứng (react) có vùng tối ưu rộng quanh 0.01–0.02 (chỉ xấu khi đẩy lên 0.1); cận (clamp) an toàn ở khoảng 0.5–2. Nói cách khác, ngoài quy tắc $k \approx \sqrt{N}$, kỹ thuật không đòi hỏi dò siêu tham số công phu.



Hình 10. Ablation siêu tham số (E15). Trục tung là L1 (ngưỡng 0.15 ở trên cùng). Phương pháp ổn định trên dải rộng của cả bốn siêu tham số.

6.2. Giới hạn 1 — số chiều

Đây là giới hạn quan trọng nhất và được nêu thẳng thắn. Ước lượng mật độ k-lần-cận chịu **lời nguyền số chiều**: thí nghiệm E13 cho thấy hiệu quả suy giảm theo d ($d=10$: 0.095 $\rightarrow$ $d=25$: 0.206 $\rightarrow$ $d=50$: 0.345 $\rightarrow$ $d=100$: hỏng). Biến thể khoảng cách Mahalanobis *không* cứu được (thậm chí tệ hơn). Do đó, phạm vi áp dụng khuyến nghị là **số chiều thấp đến trung bình ($d \lesssim 25$)** — điều này cần được nêu rõ trong mọi phát biểu về kỹ thuật.




Hình 11. Giới hạn số chiều (E13). kNN-BD (xanh lá) tốt tới $d \approx 20$ –25 rồi suy giảm; Mahalanobis-kNN (xanh dương) không cải thiện. Đường ngang là ngưỡng 0.15.

6.3. Giới hạn 2 — yêu cầu log-mật-độ hiệu chuẩn

Số hạng phản ứng tiêu thụ trực tiếp *giá trị* log-mật-độ (không chỉ gradient). Thí nghiệm E6 cho thấy: nhiễu **ngẫu nhiên** trên log-mật-độ (tới 0.8 nats) hầu như vô hại (được trung bình hóa qua nhiều hạt) — một tính chất bền vững tốt. Tuy nhiên, **độ lệch hệ thống** ồ

trên một mode sẽ làm méo tỉ trọng đúng theo hệ số e^δ : tỉ trọng thực hiện bám sát dự đoán lý thuyết $w_0 \cdot e^\delta / Z$. Hệ quả: kỹ thuật đòi hỏi log-mật-độ được *hiệu chuẩn*; các mô hình chỉ học score (không có log-mật-độ hiệu chuẩn) là vùng không phù hợp.



Hình 12. “Trung thành nhưng nhạy cảm” (E6). Tỉ trọng mode thực hiện (xanh) bám sát dự đoán lý thuyết e^δ (đứt nét đen) khi ta cố ý làm lệch log-mật-độ của một mode. Đây định lượng chính xác yêu cầu hiệu chuẩn.

6.4. Chi phí tính toán

Thí nghiệm E16 đo chi phí: ở $N=4000$, kNN-BD dùng ~ 1000 lần gọi gradient và ~ 5.5 giây mỗi lần chạy trên GPU. Chi phí chi phối là phép tính khoảng cách cặp (cho k-lân-cận) cỡ $O(N^2)$ — hoàn toàn khả thi ở quy mô vài nghìn hạt, và có thể tăng tốc bằng cấu trúc tìm lân cận xấp xỉ nếu cần.

7. Công trình liên quan

Birth-death cho lấy mẫu. Lu, Lu và Nolen [1] đề xuất bổ sung cơ chế birth-death vào khuếch tán Langevin và chứng minh tốc độ hội tụ của PDE trường trung bình độc lập với rào thế năng — trái ngược với sự phụ thuộc hàm mũ của Langevin thuần. Lu, Slepčev và Wang [2] củng cố kết quả này với giả thiết yếu hơn và, quan trọng cho chúng tôi, chứng minh sự **Γ -hội tụ** của động lực học được nhân hóa (kernelized) về birth-death thuần khi bằng thông **cố định** co về 0. Công trình của chúng tôi mang tính thực nghiệm và bổ sung: chỉ ra rằng ở bằng thông cố định/toàn cục, ước lượng số hạng phản ứng thất bại trên mục tiêu heteroscedastic, và đề xuất bằng thông thích nghi.

Dòng chảy Fisher-Rao và phương pháp hạt. Maurais và Marzouk [3] xây dựng dòng chảy kernel Fisher-Rao lấy mẫu trong thời gian đơn vị, dùng biểu diễn RKHS cho trường vận tốc/tốc độ phản ứng. Đây là phương pháp gần nhất về mặt lý thuyết với kỹ thuật của chúng tôi; khác biệt then chốt là RKHS *toàn cục* so với mật độ k-lân-cận *cục bộ* (xem mục 4). Stein Variational Gradient Descent [7] là một phương pháp hạt tương tác phổ biến khác, nhưng nổi tiếng gặp khó với tỉ trọng mode.

Sequential Monte Carlo và lấy mẫu lại. Annealed Importance Sampling [4] và SMC samplers [5] là các baseline mạnh dựa trên chuỗi phân phối trung gian; chúng còn cho ước lượng hằng số chuẩn hóa như sản phẩm phụ. Việc lựa chọn sơ đồ lấy mẫu lại có ảnh

hường lớn đến phương sai [6]; chúng tôi dùng systematic resampling và định lượng lợi ích của nó bằng ablation trực tiếp (Hình 4).

Ước lượng mật độ và thống kê khoảng cách. Ước lượng mật độ k-lân-cận là công cụ phi tham số cổ điển [10]; đóng góp của chúng tôi là đưa nó vào vai trò ước lượng số hạng phản ứng của birth-death cùng quy tắc chọn k. Thước đo energy distance [11] và bài toán hoán nhãn trong mô hình hỗn hợp [12] cung cấp công cụ đánh giá khách quan.

7.1. Bối cảnh 2025–2026 và định vị đóng góp

Nhánh cạnh tranh trực tiếp. Crucinio và Pathiraja [14, 15] là công trình gần nhất: họ xấp xỉ dòng chảy WFR bằng Langevin kết hợp importance sampling và báo cáo vượt birth-death Langevin. Mục 4.1 dành riêng cho so sánh trực tiếp với nhánh này. Khác biệt cấu trúc: phương pháp của họ cần một phân phối tham chiếu tính được mật độ, kỹ thuật của chúng tôi ước lượng mật độ cục bộ ngay từ đám hạt.

Bối cảnh đánh giá. Grenioux, Noble và Gabrié [16] lập luận rằng cộng đồng cần đánh giá bộ lấy mẫu một cách hệ thống theo độ tách mode và số chiều, với tiêu chí trọng tâm là *phục hồi tỉ trọng tương đối giữa các mode* — đúng thước đo được dùng xuyên suốt báo cáo này. Công trình đó đề xuất khung *đánh giá*; chúng tôi đóng góp một *phương pháp* theo đúng tiêu chí đó.

Định vị trung thực về bằng chứng thích nghi. Cần nói rõ: bằng chứng thích nghi k-lân-cận **không phải ý tưởng mới**. Nó là công cụ cổ điển [10], đã được phân tích kỹ trong ước lượng phiếm hàm mật độ với đúng động lực hỗn hợp phương sai không đồng nhất [19], và gần đây được áp dụng cho việc chọn nhân của SVGD [17]. Đóng góp của chúng tôi **không** nằm ở việc phát minh bằng chứng kNN, mà ở ba điểm hẹp hơn và kiểm chứng được: (i) đưa mật độ kNN *cục bộ* vào vai trò ước lượng **số hạng phản ứng của birth-death**, nơi trước đây chỉ dùng nhân bằng chứng toàn cục; (ii) bản đồ thất bại phân loại vì sao các lựa chọn thay thế hỏng; (iii) quy tắc $k \approx \sqrt{N}$ kèm bằng chứng thực nghiệm và ablation đầy đủ. Các hướng lấy mẫu đa mode song song khác trong giai đoạn này — ví dụ tôi luyện có bảo đảm lý thuyết và tiền điều kiện hóa cho số chiều lớn [18] — giải quyết bài toán ở tầng khác và có thể bổ trợ.

8. Kết luận và hướng phát triển

Báo cáo trình bày **kNN-BD**, một kỹ thuật lấy mẫu birth-death với bằng chứng thích nghi k-lân-cận. Đóng góp gồm ba phần bổ trợ nhau: (i) **chẩn đoán** — chỉ ra và phân loại vì sao các ước lượng số hạng phản ứng bằng bằng chứng toàn cục thất bại trên mục tiêu phương sai không đồng nhất; (ii) **phương pháp** — một sửa đổi đơn giản (kNN thích nghi + quy tắc $k \approx \sqrt{N}$ + systematic resampling) vượt mọi baseline SOTA ở cùng ngân sách và điều kiện; (iii) **đặc trưng hóa** — xác định rõ phạm vi áp dụng ($d \leq 25$, log-mật-độ hiệu chuẩn) qua các thí nghiệm giới hạn.

Toàn bộ được kiểm chứng qua 18 nhóm thí nghiệm với error bar, trên cả mục tiêu giải tích, mục tiêu học bằng mạng nơ-ron, và hậu nghiệm Bayesian thực, bao gồm so sánh trực tiếp với nhánh nghiên cứu cạnh tranh mới nhất (mục 4.1).

Hướng phát triển. Về lý thuyết, hướng tự nhiên là mở rộng chứng minh **Γ -hội tụ** (Gamma-convergence) của động lực học birth-death từ trường hợp bằng chứng cố định (Lu-Slepčev-Wang) sang bằng chứng biến thiên k-lân-cận — trong đó quy tắc $k \approx \sqrt{N}$ xuất

hiện tự nhiên như điều kiện để chứng minh hội tụ. Đây là chặng dùng giải tích hàm (không gian Sobolev, hội tụ độ đo), có thể nâng công trình từ cấp workshop lên cấp hội nghị. Về ứng dụng, hướng mở rộng số chiều (ví dụ ước lượng mật độ trong không gian đặc trưng học được) là bài toán mở đáng theo đuổi.

Phụ lục A — Bảng số đầy đủ (trích)

Thí nghiệm	Đại lượng	kNN-BD	Baseline / ghi chú
E1 Bản đồ thất bại	L1	0.092 ± 0.005	median 1.600; ULA 0.334
E3 Resampling	L1 churn	$0.092 \mid 0.005$	multinomial 0.112 0.026
E4 Mục tiêu neural	L1 (k=63)	0.031 ± 0.003	ULA 0.052
E8 vs PT/SVGD	L1	0.095 ± 0.004	PT 0.386; SVGD 0.335
E9 Hậu nghiệm hoán nhãn	L1 (chuẩn=0)	0.012 ± 0.005	ULA 0.998 ± 0.003
E10 Bất đẳng hướng	L1	0.099 ± 0.005	ULA 0.338
E11 vs SOTA	L1	0.095 ± 0.004	AIS 0.319; KFR 0.281
E12 Hằng số chuẩn hóa	sai số log Z	—	AIS 0.103 (gate PASS)
E13 Số chiều	L1	d25:0.206; d100:1.0	giới hạn $d \leq 25$
E14 Theo N	độ dốc log-log	-0.15	$k = \sqrt{N}$
E17 Ổn định (10 seed)	L1	0.093 ± 0.005	cấu hình chính
E18b vs SMC-WFR	L1 (10 seed)	0.093 ± 0.005	SMC-WFR 0.265; thắng 10/10
E18c không tham chiếu	L1 (10 seed)	0.093 ± 0.005	oracle 0.071 (hòa); KDE 0.224

Phụ lục B — Tái lập kết quả

Toàn bộ thí nghiệm nằm trong một tệp Python duy nhất (wfr_all.py), chạy tuần tự E1→E17, tự lưu checkpoint (CSV) và có khả năng resume khi phiên làm việc bị ngắt. Chạy đầy đủ trên GPU T4:

```
python wfr_all.py
```

Mỗi thí nghiệm sinh tệp kết quả wfr_results/E*.csv và các hình fig1–fig12. Tổng thời gian ước tính vài giờ trên một GPU T4. Nhóm thí nghiệm E18 (so sánh trực tiếp với SMC-WFR, mục 4.1) nằm trong tệp riêng wfr_e18.py, dùng chung thư mục kết quả và sinh thêm fig13_e18.png:

```
python wfr_e18.py # 3 seed WFR_SEEDS=10 python wfr_e18.py # 10 seed
```

Tài liệu tham khảo

- [1] Y. Lu, J. Lu, and J. Nolen. Accelerating Langevin sampling with birth-death. arXiv:1905.09863, 2019.
- [2] Y. Lu, D. Slepčev, and L. Wang. Birth-death dynamics for sampling: global convergence, approximations and their asymptotics. *Nonlinearity*, 36(11):5731–5772, 2023. doi:10.1088/1361-6544/acf988.
- [3] A. Muraïs and Y. Marzouk. Sampling in unit time with kernel Fisher-Rao flow. In *Proc. 41st International Conference on Machine Learning (ICML)*, PMLR 235:35138–35162, 2024.
- [4] R. M. Neal. Annealed importance sampling. *Statistics and Computing*, 11:125–139, 2001.
- [5] P. Del Moral, A. Doucet, and A. Jasra. Sequential Monte Carlo samplers. *Journal of the Royal Statistical Society: Series B*, 68(3):411–436, 2006.
- [6] R. Douc and O. Cappé. Comparison of resampling schemes for particle filtering. In *Proc. 4th International Symposium on Image and Signal Processing and Analysis (ISPA)*, pp. 64–69, IEEE, 2005.
- [7] Q. Liu and D. Wang. Stein variational gradient descent: a general purpose Bayesian inference algorithm. In *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 29, 2016.
- [8] C. J. Geyer. Markov chain Monte Carlo maximum likelihood. In *Computing Science and Statistics: Proc. 23rd Symposium on the Interface*, pp. 156–163, 1991. (Parallel tempering / replica exchange; xem thêm Swendsen & Wang, *Phys. Rev. Lett.* 57:2607, 1986.)
- [9] G. O. Roberts and R. L. Tweedie. Exponential convergence of Langevin distributions and their discrete approximations. *Bernoulli*, 2(4):341–363, 1996. (Unadjusted Langevin Algorithm.)
- [10] D. O. Loftsgaarden and C. P. Quesenberry. A nonparametric estimate of a multivariate density function. *Annals of Mathematical Statistics*, 36(3):1049–1051, 1965. (k-nearest-neighbour density estimation.)
- [11] G. J. Székely and M. L. Rizzo. Energy statistics: a class of statistics based on distances. *Journal of Statistical Planning and Inference*, 143(8):1249–1272, 2013.
- [12] A. Jasra, C. C. Holmes, and D. A. Stephens. Markov chain Monte Carlo methods and the label switching problem in Bayesian mixture modeling. *Statistical Science*, 20(1):50–67, 2005.
- [13] P. Del Moral, A. Doucet, and A. Jasra. On adaptive resampling strategies for sequential Monte Carlo methods. *Bernoulli*, 18(1):252–278, 2012.
- [14] F. R. Crucinio and S. Pathiraja. Sequential Monte Carlo approximations of Wasserstein-Fisher-Rao gradient flows. arXiv:2506.05905, 2025 (bản cập nhật 2026).
- [15] F. R. Crucinio and S. Pathiraja. Wasserstein Fisher-Rao gradient flows: operator splitting and convergence speed. *NeurIPS Workshop on Dynamics at the Frontiers of Optimization, Sampling, and Games*, 2025.
- [16] L. Grenioux, M. Noble, and M. Gabrié. Improving the evaluation of samplers on multi-modal targets. *ICLR 2025 Workshop “Frontiers in Probabilistic Inference: Learning meets Sampling”*. arXiv:2504.08916, 2025.
- [17] M. Melcher, S. Weissmann, A. Wilson, and J. Zech. Adaptive kernel selection for Stein variational gradient descent. arXiv:2510.02067, 2025 (NeurIPS 2025 Workshop).
- [18] L. Baldassari, J. Garnier, K. Sølna, and M. V. de Hoop. Dimension-free multimodal sampling via preconditioned annealed Langevin dynamics. arXiv:2602.01449, 2026.
- [19] W. Gao, S. Oh, and P. Viswanath. Density functional estimators with k-nearest neighbor bandwidths. arXiv:1702.03051, 2017.

Ghi chú: danh mục nêu các công trình nền tảng, các baseline được so sánh trực tiếp, và các công trình 2025–2026 liên quan gần nhất [14]–[19]. Baseline SMC-WFR ở mục 4.1 là bản tái hiện của chúng tôi từ mô tả thuật toán trong [14], không phải mã nguồn của nhóm tác giả. Hướng lý thuyết Γ -hội tụ cho bằng

thông biến thiên (mục 8) mở rộng khuôn khổ của [2].